

RAG (retrieval-augmented generation)

RAG em IA é um framework usado para otimizar o desempenho de grandes modelos de linguagem ([LLM](#)). O RAG cria uma conexão entre o LLM e sistemas de recuperação de informação externos, aumentando suas fontes de informação, resultando na melhora em sua capacidade de respostas mediante informações mais atuais e relevantes.

O processo RAG ajuda a resolver a limitação de um LLM ao buscar informação. Ao usar um protocolo [MCP \(model context protocol\)](#), o modelo LLM pode acessar informações em fontes externas como dados organizacionais, periódicos acadêmicos e conjuntos de dados especializados.

Os modelos de [IA generativa](#) (IA gen) são treinados em grandes conjuntos de dados e o RAG é um processo que amplia a capacidade de pesquisa e sintetização de respostas. Ao integrar informações relevantes ao processo de geração, os [chatbots](#) e outras ferramentas de [processamento de linguagem natural \(NLP\)](#) podem criar conteúdos específicos de domínio mais precisos sem a necessidade de treinamento adicional.

Quais são os benefícios da RAG?

A RAG capacita as organizações a evitar altos custos de requalificação ao adaptar modelos de IA generativa a casos de uso específicos do domínio. As empresas podem usar a RAG para preencher as lacunas na base de conhecimento de um modelo de [aprendizado de máquina](#), para que ele possa fornecer respostas melhores.

Os principais benefícios da RAG incluem:

- Implementação econômica da IA e [escalabilidade da IA](#)

- Acesso a dados atuais específicos do domínio

- Menor risco de [alucinações da IA](#)

- Aumento da confiança do usuário

- Expansão de casos de uso

- Melhoria do controle de desenvolvedores e manutenção de modelos

Maior segurança de dados

Implementação econômica da IA e escalabilidade da IA

Ao implementar a IA, a maioria das organizações primeiro seleciona um modelo de base: os modelos de [deep learning](#) que servem de base para o desenvolvimento de versões mais avançadas. Os modelos de base normalmente têm bases de conhecimento generalizadas preenchidas com dados de treinamento disponíveis publicamente, como conteúdo da internet disponível no momento do treinamento.

Retreinar um modelo de base ou realizar seu [ajuste fino](#) (onde um modelo de base é treinado ainda mais com novos dados em um conjunto de dados menor e específico do domínio) é computacionalmente caro e consome muitos recursos. O modelo ajusta alguns ou todos os seus parâmetros para ajustar seu desempenho aos novos dados especializados.

Com a RAG, as empresas podem usar fontes de dados internas confiáveis e obter aumentos semelhantes no desempenho de modelos sem retreinamento. As empresas podem escalar a implementação de aplicações de IA conforme a necessidade, mitigando os aumentos nos custos e requisitos de recursos.

Acesso a dados atuais e específicos do domínio

Os modelos de IA generativa têm um *limite de conhecimento*, o ponto em que os dados de treinamento foram atualizados pela última vez. À medida que um modelo envelhece além de seu limite de conhecimento, ele perde relevância ao longo do tempo. Os sistemas de RAG conectam modelos a dados externos complementares em tempo real e incorporam informações atualizadas nas respostas geradas.

As empresas usam a RAG para equipar modelos com informações específicas, como dados proprietários de clientes, pesquisas confiáveis e outros documentos relevantes.

Os modelos de RAG também podem se conectar à internet com [interfaces de programação de aplicativos \(APIs\)](#) e ter acesso a feeds de redes sociais em tempo real e avaliações de consumidores para uma melhor compreensão da opinião do mercado. Enquanto isso, o acesso a notícias de última hora e mecanismos de busca

pode levar a respostas mais precisas à medida que os modelos incorporam as informações recuperadas no processo de geração de texto.

Menor risco de alucinações de IA

Modelos de IA generativa, como o [GPT](#) da OpenAI, funcionam detectando padrões nos dados e, em seguida, usando esses padrões para prever os resultados mais prováveis das entradas dos usuários. Às vezes, os modelos detectam padrões que não existem. Uma alucinação ou confabulação acontece quando modelos apresentam informações incorretas ou inventadas como se fossem fatos.

A RAG ancora os LLMs em um conhecimento específico apoiado por dados factuais, confiáveis e atuais. Em comparação com um modelo generativo que opera apenas em seus dados de treinamento, os modelos de RAG tendem a apresentar respostas mais precisas dentro dos contextos de seus dados externos. Embora a RAG possa reduzir o risco de alucinações, ela não pode tornar um modelo à prova de erros.

Aumento da confiança do usuário

Os [chatbots](#), uma implementação comum de IA generativa, respondem a perguntas feitas por usuários humanos. Para que um chatbot como o ChatGPT seja bem-sucedido, os usuários precisam ver sua saída como confiável. Os modelos de RAG podem incluir citações às fontes de conhecimento em seus dados externos como parte de suas respostas.

Quando os modelos de RAG citam suas fontes, os usuários humanos podem verificar essas saídas para confirmar a precisão enquanto consultam os trabalhos citados para esclarecimentos de acompanhamento e informações adicionais. O armazenamento de dados corporativos costuma ser um labirinto complexo e isolado. As respostas da RAG com citações direcionam os usuários diretamente para os materiais de que precisam.

Expansão de casos de uso

O acesso a mais dados significa que um modelo pode lidar com uma gama mais ampla de prompts. As empresas podem otimizar modelos e obter mais valor deles ao ampliar suas bases de conhecimento, o que, por sua vez, expande os contextos nos quais esses modelos geram resultados confiáveis.

Ao combinar a IA generativa com sistemas de recuperação, os modelos de RAG podem recuperar e integrar informações de várias fontes de dados em resposta a consultas complexas.

Melhoria do controle de desenvolvedores e manutenção de modelos

As organizações modernas processam constantemente grandes quantidades de dados, desde entradas de pedidos até projeções de mercado, rotatividade de funcionários e muito mais. A construção e o armazenamento de dados eficazes do [pipeline de dados](#) são fundamentais para uma implementação sólida da RAG.

Ao mesmo tempo, desenvolvedores e [cientistas de dados](#) podem ajustar as fontes de dados às quais os modelos têm acesso a qualquer momento. Reposicionar um modelo de uma tarefa em outra se torna uma tarefa de ajustar suas fontes externas de conhecimento em vez de ajustes finos ou retreinamento. Se for necessário um ajuste fino, os desenvolvedores podem priorizar esse trabalho em vez de gerenciar as fontes de dados do modelo.

Maior segurança de dados

Como a RAG conecta um modelo a fontes de conhecimento externas em vez de incorporar esse conhecimento aos dados de treinamento do modelo, ela mantém uma divisão entre o modelo e esse conhecimento externo. As empresas podem usar a RAG para preservar os dados primários e, ao mesmo tempo, conceder aos modelos acesso a eles — acesso que pode ser revogado a qualquer momento.


No entanto, as empresas devem estar atentas para manter a segurança dos próprios bancos de dados externos. A RAG usa [bancos de dados de vetores](#), que usam para converter pontos de dados em representações numéricas. Se esses bancos de dados forem violados, os invasores poderão reverter o processo de [embedding](#) e acessar os dados originais, especialmente se o banco de dados de vetores não estiver criptografado.

Como a RAG funciona?

A RAG funciona combinando modelos de recuperação de informações com modelos de IA generativa para produzir conteúdo mais confiável. Os sistemas de RAG consultam uma base de conhecimento e adicionam mais contexto a um prompt do usuário antes de gerar uma resposta.

LLMs padrão obtêm informações de seus conjuntos de dados de treinamento. A RAG adiciona um componente ao fluxo de trabalho de IA, reunindo informações relevantes e alimentando o modelo de IA generativa para melhorar a qualidade e a utilidade das respostas.

Os sistemas de RAG seguem um processo de cinco estágios:



O usuário envia um prompt.

O modelo de **recuperação** de informações consulta a base de conhecimento em busca de dados relevantes.

As informações relevantes são retornadas da base de conhecimento para a camada de integração.

O sistema de RAG cria um prompt **aumentado** para o LLM com contexto aprimorado a partir dos dados recuperados.

O LLM **gera** uma saída e retorna uma saída para o usuário.

Esse processo mostra como a RAG recebe seu nome. O sistema de RAG *recupera* dados da base de conhecimento, *aumenta* o prompt com contexto adicional e *gera* uma resposta.

Componentes de um sistema de RAG

Os sistemas de RAG contêm quatro componentes principais:

A **base de conhecimento**: o repositório de dados externo do sistema.

O **recuperador**: um modelo de IA que procura dados relevantes na base de conhecimento.

A **camada de integração**: a parte da arquitetura de RAG que coordena seu funcionamento geral.

O **gerador**: um modelo de IA generativa que cria uma saída com base na consulta do usuário e nos dados recuperados.

Outros componentes podem incluir um *classificador*, que classifica os dados recuperados com base na relevância e um *manipulador de saída*, que formata a resposta gerada para o usuário.

A base de conhecimento

O primeiro estágio na criação de um sistema de RAG é criar uma base de conhecimento consultável. O repositório de dados externo pode conter dados de inúmeras fontes: PDFs, documentos, guias, sites, arquivos de áudio e muito mais. Muito disso serão dados **não estruturados**, o que significa que ainda não foram rotulados.

Os sistemas de RAG usam um processo chamado embedding para transformar dados em representações numéricas chamadas vetores. O modelo de embedding vetoriza os dados em um espaço matemático multidimensional, organizando os pontos de dados por similaridade. Os pontos de dados considerados mais próximos em termos de relevância são colocados próximos uns dos outros.

As bases de conhecimento devem ser continuamente atualizadas para manter a qualidade e relevância do sistema de RAG.

As entradas de LLMs são limitadas à janela de contexto do modelo: a quantidade de dados que ele pode processar sem perder o contexto. *Fragmentar* um documento em tamanhos menores ajuda a garantir que as embeddings resultantes não sobrecarreguem a janela de contexto do LLM no sistema de RAG.

O tamanho do fragmento é um hiperparâmetro importante para o sistema de RAG. Quando os fragmentos são muito grandes, os pontos de dados podem se tornar muito gerais e não corresponderem diretamente às possíveis consultas do usuário.

Mas se os fragmentos forem muito pequenos, os pontos de dados podem perder coerência semântica.

O recuperador

A vetorização dos dados prepara a base de conhecimento para a [pesquisa de vetores](#) semântica, uma técnica que identifica pontos no banco de dados que são semelhantes à consulta do usuário. [Algoritmos de aprendizado de máquina](#) de pesquisa semântica podem consultar bancos de dados imensos e identificar rapidamente informações relevantes, reduzindo a latência em comparação com pesquisas de palavras-chave tradicionais.

O modelo de recuperação de informações transforma a consulta do usuário em um embedding e, em seguida, pesquisa a base de conhecimento em busca de embeddings semelhantes. Em seguida, suas descobertas são retornadas da base de conhecimento.

A camada de integração

A camada de integração é o centro da arquitetura de RAG, coordenando os processos e transmitindo dados pela rede. Com os dados adicionados da base de conhecimento, o sistema de RAG cria um novo prompt para o componente do LLM. Esse prompt consiste na consulta original do usuário mais o contexto aprimorado retornado pelo modelo de recuperação.

Os sistemas de RAG empregam várias técnicas de [engenharia de prompts](#) para automatizar a criação eficaz de prompts e ajudar o LLM a retornar a melhor resposta possível. Enquanto isso, frameworks de orquestração de LLMs, como o [LangChain](#) e o [LlamaIndex](#), de código aberto, ou o [IBM® watsonx Orchestrate](#), governam o funcionamento geral de um sistema de IA.

O gerador

O gerador cria uma saída com base no prompt aumentado alimentado a ele pela camada de integração. O prompt sintetiza a entrada do usuário com os dados recuperados e instrui o gerador a considerar esses dados em sua resposta. Os geradores normalmente são modelos de linguagem pré-treinados, como o GPT, [Claude](#) ou [Llama](#).

A [diferença entre RAG e ajuste fino](#) é que a RAG permite que um LLM consulte uma fonte de dados externa, enquanto o ajuste fino treina um LLM em dados específicos

do domínio. Ambos têm o mesmo objetivo geral: fazer com que um LLM tenha um desempenho melhor em um domínio específico.

A RAG e o ajuste fino são frequentemente contrastados, mas podem ser usados em conjunto. O ajuste fino aumenta a familiaridade de um modelo com o domínio pretendido e os requisitos de saída, enquanto a RAG auxilia o modelo na geração de saídas relevantes e de alta qualidade.

FONTE: <https://www.ibm.com/br-pt/think/topics/retrieval-augmented-generation>