

banco de dados vetorial

Um banco de dados de vetores armazena, gerencia e indexa dados vetoriais de alta dimensão.

Em um banco de dados de vetores, os pontos de [dados](#) são armazenados como matrizes de números chamadas "vetores", que podem ser comparadas e agrupadas com base na similaridade. Esse design permite consultas de baixa [latência](#), tornando-o ideal para aplicações de [inteligência artificial](#) (IA).

Os bancos de dados de vetores estão crescendo em popularidade porque oferecem a velocidade e o desempenho necessários para impulsionar os casos de uso da [IA generativa](#). Na verdade, de acordo com a pesquisa de 2025, [a adoção do banco de dados de vetores cresceu 377% ano após ano](#)— o crescimento mais rápido relatado em qualquer tecnologia relacionada a grandes modelos de linguagem (LLM).

Bancos de dados de vetores vs. bancos de dados tradicionais

A natureza dos dados mudou drasticamente nos últimos anos. Não está mais confinada a informações estruturadas armazenadas ordenadamente nas linhas e colunas dos bancos de dados tradicionais. [Os dados não estruturados](#)— incluindo postagens em mídias sociais, imagens, vídeos e áudio – estão crescendo em volume e valor, remodelando as estratégias de IA empresarial e ao mesmo tempo colocando novas demandas na infraestrutura de dados.

Os [bancos de dados relacionais](#) tradicionais são excelentes no gerenciamento de [conjuntos de dados estruturados e semiestruturados](#) dentro de [esquemas](#) definidos. Entretanto, carregar e preparar dados não estruturados em um banco de dados relacional para cargas de trabalho de IA é trabalhoso.

A busca tradicional agrava essa limitação: ela se baseia em tokens discretos, como palavras-chave, tags ou [metadados](#), e retorna os resultados com base em correspondências exatas. Uma busca por "smartphone", por exemplo, retorna apenas conteúdos que contenham esse termo específico.

Os bancos de dados de vetores adotam uma abordagem fundamentalmente diferente. Em vez de linhas e colunas, os pontos de dados são representados como vetores densos, onde cada dimensão representa uma característica aprendida dos dados. Essas representações vetoriais de alta dimensão existem no espaço vetorial, onde as relações entre os itens podem ser medidas geometricamente.

Como cada dimensão representa uma funcionalidade latente, uma característica inferida aprendida por meio de modelos matemáticos e algoritmos, as representações vetoriais capturam padrões ocultos. Uma pesquisa vetorial por "smartphone" também pode retornar resultados semanticamente relacionados, como "celular" ou "dispositivo móvel", mesmo que essas palavras exatas não apareçam.

Ao modelar dados em um espaço de alta dimensão e aplicar técnicas de indexação especializadas, o banco de dados vetorial possibilita realizar buscas similares de baixa latência em grandes [conjuntos de dados](#), algo que os bancos de dados relacionais não foram projetados para suportar.

Por que os bancos de dados de vetores são importantes?

A rápida ascensão dos LLMs, dos sistemas generativos de IA e dos fluxos de trabalho avançados de [processamento de linguagem natural](#) (PNL) mudou a forma como as organizações lidam e armazenam dados. As [cargas de trabalho de IA](#) atuais dependem de uma interação rápida e em tempo real com dados vetoriais, bem como da integração sem dificuldades com pipelines de [geração aumentada de recuperação](#) (RAG).

Os bancos de dados vetoriais fornecem a infraestrutura para suportar essas demandas. Eles permitem pesquisas de similaridade de baixa latência em grandes volumes de [dados não estruturados](#), impulsionando aplicações de IA, como [chatbots](#) e [sistemas de recomendação](#).

Conceitos fundamentais dentro de bancos de dados de vetores

Para entender como funciona um banco de dados de vetores, vale a pena estabelecer dois conceitos fundamentais: vetores, que descrevem dados em formato numérico, e embedding vetorial, que traduz o conteúdo não estruturado em representações de alta dimensão que capturam significado e contexto.

Vetores

Os vetores são um subconjunto dos tensores. No [aprendizado de máquina](#) (ML), tensor é um termo genérico para um grupo de números – ou um agrupamento de grupos de números – em espaço n-dimensional. Os tensores funcionam como um dispositivo matemático para registro dos dados. Partindo do menor elemento:

Um **escalar** é um tensor de dimensão zero, que contém um único número.

Por exemplo, um sistema que modela dados meteorológicos pode representar a temperatura máxima de um único dia (em Fahrenheit) na forma escalar como 85.

Um **vetor** é um tensor unidimensional (ou de primeiro grau ou de primeira ordem), que contém múltiplos escalares do mesmo tipo de dados. Com base no nosso exemplo, um modelo meteorológico pode usar as temperaturas mínimas, médias e máximas de um único dia em forma vetorial: 62, 77, 85.

Cada componente escalar é uma funcionalidade – isto é, uma dimensão – do vetor, representando uma característica do clima daquele dia.

Em outras palavras, os vetores são uma forma de organizar números de uma forma estruturada. Mas para que os sistemas de IA processem essas informações não estruturadas, os dados devem ser traduzidos em matrizes numéricas. Essa tradução é alcançada por meio de embeddings vetoriais.

Embeddings vetoriais

[Embeddings vetoriais](#) são representações numéricas de pontos de dados que convertem vários tipos de dados, incluindo texto e imagens, em matrizes de números que modelos de ML podem processar.

Para alcançar esse objetivo, os [modelos de embedding](#) aprendem a mapear os dados de inputs em um espaço vetorial de alta dimensão. Esse espaço vetorial reflete padrões aprendidos por meio de uma função de perda específica da tarefa, que quantifica os erros de previsão. Os embeddings vetoriais podem então ser

usados por modelos de IA subsequentes, como [redes neurais](#) usadas no [deep learning](#), para executar tarefas como classificação, recuperação ou agrupamento.

Considere um pequeno conjunto de palavras, onde os [embedding das palavras](#) são representados como vetores tridimensionais:

gato [0,2, -0,4, 0,7]

cachorro [0,6, 0,1, 0,5]

Neste exemplo, cada palavra ("gato") está associada a um vetor único ([0,2, -0,4, 0,7]). Os valores no vetor representam a posição da palavra em um espaço vetorial tridimensional. É esperado que palavras com significados ou contextos semelhantes tenham representações vetoriais similares. Os vetores para "gato" e "cachorro" estariam próximos, refletindo sua relação semântica.

Da mesma forma, as palavras "carro" e "veículo" compartilham o mesmo significado, mas são escritas de forma diferente. Para que uma aplicação de IA realize uma busca semântica, as representações vetoriais de "carro" e "veículo" devem capturar o significado que compartilham. Os embeddings vetoriais codificam esse significado numericamente, tornando-os a base de motores de recomendação, chatbots e aplicações generativas como o [ChatGPT](#) da OpenAI.

Como funcionam os bancos de dados de vetores?

Para facilitar a recuperação semântica rápida e escalável, os bancos de dados de vetores contam com três funções principais:

Armazenamento de vetores

Indexação vetorial

Pesquisa vetorial

Armazenamento de vetores

Em um nível fundamental, os bancos de dados de vetores armazenam embeddings. Cada um tem um número fixo de dimensões e normalmente é armazenado juntamente com metadados, como título, fonte, registro de data/hora ou categoria, que podem ser consultados usando filtros de metadados.

Como os embeddings são gerados previamente e armazenados, os bancos de dados de vetores podem recuperar os embeddings semelhantes sem recalculá-los no momento da consulta. Essa separação entre geração e recuperação viabiliza a busca por similaridade de baixa latência em escala.

Muitos sistemas também são compatíveis com a busca híbrida que combina similaridade vetorial com restrições de metadados – por exemplo, recuperando documentos semanticamente semelhantes criados dentro de um intervalo de datas ou categoria específicos.

Indexação vetorial

Para acelerar a busca por similaridade em um espaço de alta dimensão, o banco de dados de vetores cria índices no embedding de vetores armazenados. A indexação mapeia os vetores para novas estruturas de dados, permitindo buscas mais rápidas por similaridade ou distância entre vetores.

Esses índices são compatíveis com a busca aproximada por vizinho mais próximo (ANN, na sigla em inglês), que recupera vetores semelhantes sem precisar examinar todo o conjunto de dados. Os algoritmos comuns de indexação de ANN incluem o algoritmo hierárquico de mundo pequeno navegável (HNSW) e hashing sensível à localidade (LSH):

O **HNSW** cria um gráfico hierárquico de várias camadas que usa links de longo alcance nas camadas superiores e links locais densos na camada inferior.¹

O **LSH** agrupa os vetores em [categorias](#) usando uma função de hash para que vetores semelhantes caiam na mesma categoria.

Além dos índices de ANN, os bancos de dados de vetores geralmente usam a quantização do produto (PQ) para reduzir o uso de memória. A PQ converte cada conjunto de dados em um código curto que preserva a distância relativa (em vez de armazenar todos os vetores), permitindo que os sistemas armazenem coleções maiores e, ao mesmo tempo, mantenham um desempenho de pesquisa eficiente.

Pesquisa vetorial

A **busca vetorial** é a camada de recuperação de um banco de dados de vetores usada para descobrir e comparar pontos de dados semelhantes. Em vez de buscar correspondências exatas por palavras-chave ou valores, ela captura as relações semânticas entre os elementos. Esse recurso de recuperação baseado no contexto é a base dos sistemas RAG, que, por sua vez, fornecem um contexto relevante para sistemas de IA e modelos de aprendizado de máquina baseados em recuperação.

Quando um usuário faz um prompt a um modelo de IA, o modelo gera um embedding dessa consulta, conhecida como um vetor de consulta. O banco de dados então compara o vetor de consulta com vetores indexados e calcula as pontuações de similaridade para identificar os vizinhos mais próximos.

A busca vetorial aplica múltiplos algoritmos para realizar uma busca ANN. Esses algoritmos são reunidos em um **pipeline** para recuperar de forma rápida e precisa os dados próximos ao vetor consultado (por exemplo, produtos visualmente semelhantes em um catálogo de comércio eletrônico). Como os embeddings são pré-computados e armazenados em um formato indexado, os resultados são retornados em milissegundos.

Depois que os vetores relevantes são identificados, eles são comparados calculando sua similaridade ou com uma **métrica de distância**. Métodos comuns incluem:

Similaridade de cosseno: mede a distância angular entre vetores para determinar o quão alinhados eles estão em termos de direção.

Similaridade de Jaccard: compara a sobreposição entre dois conjuntos em relação aos seus elementos totais.

Produto escalar: avalia a similaridade com base na magnitude e direção dos vetores.

Distância euclidiana: calcula a distância em linha reta entre vetores em um espaço de alta dimensão.

Distância de Hamming: conta as diferenças de posição entre vetores binários.

O banco de dados retorna os vetores com classificação mais alta de acordo com esses cálculos de similaridade, oferecendo suporte a tarefas de aprendizado de máquina, como pesquisa semântica e outros fluxos de trabalho de processamento de linguagem natural.

Quais são os benefícios dos bancos de dados de vetores?

Os bancos de dados de vetores estão se tornando cada vez mais centrais para as estratégias de [IA empresarial](#) porque oferecem uma série de benefícios:

Velocidade e desempenho: os bancos de dados de vetores usam várias técnicas de indexação para permitir pesquisas mais rápidas. Algoritmos de indexação vetorial e cálculo de distância podem ajudar a otimizar o desempenho ao buscar resultados relevantes em conjuntos de dados com milhões, se não bilhões, de pontos de dados.

Escalabilidade: os bancos de dados de vetores podem armazenar e gerenciar grandes quantidades de dados não estruturados, escalando horizontalmente com nós adicionais, mantendo o desempenho conforme as demandas de consulta e os volumes de dados aumentam.

Custo total de propriedade reduzido: como possibilitam uma recuperação de dados mais rápida, os bancos de dados vetoriais aceleram o [treinamento](#) de [modelos de base](#).

Gerenciamento de dados: os bancos de dados de vetores geralmente fornecem recursos integrados de [gerenciamento de dados](#) para atualizar e inserir facilmente novos dados não estruturados.

Flexibilidade: os bancos de dados de vetores são criados para lidar com a complexidade adicional de usar imagens, vídeos ou outros dados multidimensionais.

Casos de uso de bancos de dados de vetores

Os bancos de dados de vetores podem ser personalizados para atender a casos de uso específicos de negócios e IA. Muitas vezes, as organizações começam com um modelo de embedding de propósito geral, como o [IBM Granite](#), o Llama-2 da Meta ou o Flan do Google. Os modelos são então aprimorados usando armazenamento

de dados corporativo em um banco de dados de vetores. Essa combinação melhora a relevância e a [precisão](#) das aplicações de IA subsequentes.

As aplicações para bancos de dados de vetores são vastas e estão crescendo. Os principais casos de uso incluem:

Geração aumentada de recuperação

IA conversacional

Mecanismos de recomendação

Deteção de anomalias

Geração aumentada de recuperação

O RAG permite que os LLMs recuperem informações de uma base de conhecimento externa. As empresas favorecem cada vez mais o RAG pelo seu tempo de lançamento no mercado mais rápido, [inferência](#) eficiente e resultados confiáveis, especialmente em áreas como atenção ao cliente, RH e gerenciamento de talentos.

Ao fundamentar o modelo em [dados empresariais](#) confiáveis, o RAG reduz as [alucinações](#) e dá aos usuários acesso às fontes subjacentes para verificação. Como a etapa de inferência realiza as operações de recuperação de maior volume, ela requer acesso rápido, preciso e escalável a embedding de vetores de alta dimensão.

Os bancos de dados de vetores se destacam na indexação, armazenamento e recuperação desses embeddings, fornecendo a velocidade, precisão e escala necessárias para aplicações como sistemas de [deteção de fraude](#) e plataformas de [manutenção preditiva](#).

IA conversacional

Bancos de dados de vetores, particularmente quando usados para implementar frameworks de RAG, podem ajudar a melhorar as interações dos agentes virtuais ao aprimorar a capacidade do agente de analisar bases de conhecimento relevantes de maneira eficiente e precisa. Os agentes podem fornecer respostas contextuais [em tempo real](#) às consultas dos usuários, junto com os documentos de origem e os números das páginas para referência.

Mecanismos de recomendação

Sites de comércio eletrônico podem usar vetores para representar as preferências do cliente e os atributos do produto. Isso permite que eles melhorem a [experiência do cliente](#) e a [fidelização](#), sugerindo itens semelhantes a compras anteriores. As plataformas de [streaming](#) e os aplicativos de redes sociais aplicam a mesma abordagem, recomendando vídeos, músicas ou publicações com base na similaridade com o conteúdo que um usuário visualizou ou compartilhou anteriormente.

Detecção de anomalias

Ao representar o comportamento normal como vetores no espaço de alta dimensão, as organizações podem detectar valores discrepantes com base na distância do vetor. Os pontos de dados que se afastam muito do agrupamento estabelecido podem sinalizar fraude, falhas no sistema ou padrões de atividade incomuns. Como a similaridade é calculada matematicamente, [anomalias podem ser detectadas](#) em tempo real em conjuntos massivos de dados, desde tráfego de rede até leituras de sensores em sistemas industriais. Isso permite que as equipes interfiram antes que pequenos desvios se transformem em incidentes dispendiosos.

Embora os bancos de dados de vetores sejam adequados para recuperação baseada em fatos em muitas aplicações de IA, eles não são ideais para todos os tipos de consulta.

Cargas de trabalho como resumo de tópicos ou análise temática ampla exigem que um LLM leia todo o contexto relevante, em vez de depender apenas das correspondências dos vizinhos mais próximos. Nesses cenários, um índice em forma de lista ou outra estrutura não vetorial pode fornecer resultados mais rápidos e eficientes, já que consegue expor rapidamente os primeiros elementos relevantes sem navegar pelo espaço vetorial.

Quem usaria um banco de dados de vetores?

Os bancos de dados de vetores oferecem suporte a uma ampla variedade de cargas de trabalho de IA, mas o valor que entregam varia de acordo com a função. Na maioria das empresas, os usuários se dividem em dois grandes grupos: os construtores, que projetam e implementam experiências orientadas por IA, e os operadores, que escalam e mantêm esses sistemas em produção.

Construtores

Os construtores criam as aplicações, pipelines e modelos que dependem de pesquisa vetorial, usando banco de dados de vetores para armazenar os embeddings e alimentar as aplicações de IA.

Desenvolvedores

Os desenvolvedores contam com bancos de dados de vetores para [kits de desenvolvimento de software](#) (SDKs) específicos de [interfaces de programação de aplicativos](#) (APIs) previsíveis. Frequentemente, eles integram a busca vetorial em aplicações como chatbots e sistemas de recomendação.

Engenheiros de dados

Os [engenheiros de dados](#) projetam os pipelines que geram, transformam e validam os embeddings. Os bancos de dados de vetores simplificam os fluxos de trabalho de ingestão, a captura de metadados e o rastreamento de [linhagem](#) em ambientes de dados distribuídos.

Engenheiros de IA e ML

Os engenheiros de IA e ML operacionalizam os modelos de embedding e gerenciam a lógica de recuperação para RAG e outras cargas de trabalho de [inferência](#). Eles dependem de bancos de dados de vetores para pesquisas de baixa latência e gerenciamento de versões de embedding.

Cientistas de dados

Os [cientistas de dados](#) avaliam a qualidade do embedding e analisam o desempenho do modelo. Eles usam armazenamento de vetores para explorar dados de alta dimensão, [enriquecer](#) conjuntos de treinamento e validar relações semânticas em conjuntos de dados.

Operadores

Os operadores garantem que a carga de trabalho do vetor permaneça escalável e confiável. Eles gerenciam como os bancos de dados de vetores são executados na produção e como se encaixam em ecossistemas mais amplos de dados e IA.

Equipes de operações e SRE

As equipes de operações e [engenharia de confiabilidade local](#) (SRE) monitoram o desempenho para garantir que as consultas de vetores atendam aos requisitos de latência, taxa de transferência e disponibilidade.

Arquitetos corporativos

Os arquitetos corporativos determinam como o banco de dados de vetores se integra com o [lakehouse](#), os frameworks de [governança](#) e as [plataformas de dados existentes](#), avaliando a [interoperabilidade](#) e a adequação arquitetônica no longo prazo.

Equipes de segurança e governança

As equipes de [segurança](#) e governança garantem que os embeddings e os metadados estejam em conformidade com os requisitos corporativos e regulamentares. Elas aplicam [controles de acesso](#) e confirmam que os dados vetorizados mantêm os níveis adequados de privacidade e proteção.

Executivos de negócios e dados

Os executivos avaliam como os bancos de dados de vetores apoiam a estratégia de IA empresarial. Eles se concentram na eficiência de custos, na governança, no [gerenciamento de riscos](#) e em como os recursos vetoriais se integram aos modelos operacionais existentes.

Como escolher um banco de dados de vetores

Organizações têm uma ampla gama de opções ao escolher uma capacidade de banco de dados vetorial. Para encontrar uma que atenda às suas necessidades de dados e IA, muitas organizações consideram:

Tipos de bancos de dados vetoriais

Integração com um ecossistema de dados

Ferramentas para criar e implementar bancos de dados vetoriais

Tipos de bancos de dados de vetores

Existem algumas opções que as organizações podem escolher, incluindo:

Bancos de dados de vetores independentes: bancos de dados proprietários e totalmente vetorizados, como o Pinecone.

Bancos de dados de vetores de código aberto: soluções de [código aberto](#) como Weaviate ou Milvus, que fornecem APIs RESTful integradas e suporte para as linguagens de programação [Python](#) e [Java](#) .

Data lakehouses com recursos de vetores integrados: data lakehouses com recursos de banco de dados de vetores integrados, como o [IBM watsonx.data](#).

Extensões de vetores para bancos de dados existentes: banco de dados de vetores e extensões de pesquisa de banco de dados, como a extensão pgvector de código aberto do PostgreSQL, que fornece recursos de pesquisa de semelhança vetorial. Um banco de dados de vetores SQL pode combinar as vantagens de um [banco de dados SQL](#) tradicional com o poder de um banco de dados de vetores.

Mecanismos de busca com suporte a vetores: plataformas como o [OpenSearch](#), que fornecem a funcionalidade de busca vetorial integrada, juntamente com APIs RESTful para ingestão e consulta de embeddings.

Uma opção emergente para executar cargas de trabalho de vetores é um banco de dados de vetores sem servidor. Os projetos sem servidor eliminam a necessidade de gerenciar ou provisionar uma infraestrutura, permitindo que as equipes se concentrem na geração de embedding e no desenvolvimento de aplicações, em vez de operações de cluster. A capacidade pode escalar automaticamente com base no volume de consultas e no tamanho dos dados, ajudando as equipes a lidar com cargas de trabalho imprevisíveis sem ajuste de desempenho.

Os bancos de dados de vetores sem servidor são especialmente úteis para prototipagem rápida, aplicação de IA [orientada por eventos](#) e ambientes de desenvolvimento em que o controle de custos e a simplicidade operacional são prioridades.

Integração com um ecossistema de dados

Bancos de dados vetoriais não devem ser considerados como recursos independentes, mas sim como parte de um ecossistema mais amplo de dados e IA.

Muitos oferecem APIs, extensões nativas ou podem ser integrados com bancos de dados. Como os bancos de dados de vetores são criados para usar dados empresariais para aprimorar modelos, as organizações também devem ter uma governança de dados e segurança de dados adequadas para garantir que os dados usados para treinar LLMs possam ser confiáveis.

Além das APIs, muitos bancos de dados de vetores usam [SDKs](#) específicos para a linguagem de programação que podem complementar as [APIs](#). Ao usar os SDKs, os

desenvolvedores geralmente acham mais fácil trabalhar com os dados em suas aplicações.

Ferramentas para criar e implementar bancos de dados de vetores

Para otimizar o desenvolvimento de bancos de dados de vetores, o [LangChain](#) é um framework de orquestração de código aberto para desenvolver aplicações que utilizam LLMs.

Disponível em bibliotecas baseadas em Python e JavaScript, as ferramentas e APIs do LangChain simplificam o processo de criação de aplicações impulsionadas por LLMs, como [agentes virtuais](#) que usam armazenamentos de vetores locais e baseados na [nuvem](#). Na verdade, o LangChain fornece acesso a um amplo ecossistema com [1.000+ integrações totais](#) entre LLMs, embeddings, armazenamentos de vetores, carregadores de documentos, ferramentas e muito mais.

Um [data lakehouse](#) pode ser combinado com um banco de dados de vetores integrado para ajudar as organizações a unificar, selecionar e preparar embeddings para suas aplicações de IA generativa. Isso aumenta a relevância e a precisão de suas cargas de trabalho de IA e, em última análise, proporciona melhores resultados de negócios.

FONTE: <https://www.ibm.com/br-pt/think/topics/vector-database>