

aprendizado de máquina

O aprendizado de máquina é o subconjunto da inteligência artificial (IA) concentrado em algoritmos que podem "aprender" os padrões dos dados de treinamento e, posteriormente, fazer *inferências* precisas sobre novos dados. Essa capacidade de reconhecimento de padrões permite que os modelos de aprendizado de máquina tomem decisões ou façam previsões sem instruções explícitas e codificadas.

O aprendizado de máquina passou a dominar o campo da IA: ele fornece a base da maioria dos sistemas de IA modernos, desde modelos de [forecasting](#) até veículos autônomos, [grandes modelos de linguagem \(LLMs\)](#) e outras ferramentas de [IA generativa](#).

A premissa central do aprendizado de máquina (ML) é que, se você otimizar o desempenho de um modelo em um conjunto de dados de tarefas que se assemelha adequadamente aos problemas do mundo real para os quais ele será usado, por meio de um processo chamado [treinamento do modelo](#), o modelo pode fazer previsões precisas sobre os novos dados que ele vê no seu caso de uso final.

O treinamento em si é simplesmente um meio para um fim: a generalização, a tradução de um forte desempenho em dados de treinamento em resultados úteis em cenários do mundo real, é o objetivo fundamental do aprendizado de máquina.

Basicamente, um modelo treinado aplica padrões aprendidos nos dados de treinamento para inferir a saída correta de uma tarefa do mundo real: a implementação de um [modelo de IA](#), portanto, é chamada de [inferência de IA](#).

O [deep learning](#), o subconjunto do aprendizado de máquina orientado por grandes (ou melhor, "profundas") [redes neurais artificiais](#), surgiu nas últimas décadas como a arquitetura de modelo de IA de última geração em quase todos os domínios em que a IA é usada. Ao contrário dos algoritmos explicitamente definidos do aprendizado de máquina tradicional, o deep learning depende de "redes" distribuídas de operações matemáticas que fornecem uma capacidade incomparável de aprender

as nuances intrincadas de dados muito complexos. Como o deep learning exige grandes quantidades de dados e recursos computacionais, seu advento coincidiu com a importância cada vez maior do "big data" e das unidades de processamento gráfico (GPUs).

A disciplina do aprendizado de máquina está intimamente ligada à da ciência de dados. De certa forma, o aprendizado de máquina pode ser entendido como uma coleção de algoritmos e técnicas para automatizar a análise de dados e (ainda mais importante) aplicar os aprendizados dessa análise à execução autônoma de tarefas relevantes.

A origem do termo (embora não o conceito central em si) é frequentemente atribuída ao artigo de Arthur L. Samuel de 1959 no IBM Journal, "Some Studies in Machine Learning Using the Game of Checkers." Na introdução do artigo, Samuel articula de forma clara o resultado ideal do aprendizado de máquina: "um computador pode ser programado para aprender a jogar um jogo de damas melhor do que o que pode ser jogado pela pessoa que escreveu o programa".¹

Aprendizado de máquina versus inteligência artificial

Embora "aprendizado de máquina" e "inteligência artificial" sejam frequentemente usados de forma intercambiável, eles não são exatamente sinônimos. Resumindo: *todo aprendizado de máquina é IA, mas nem toda IA é aprendizado de máquina.*

No imaginário popular, "IA" é geralmente associada à ficção científica, geralmente por meio de representações do que é mais adequadamente chamado de inteligência artificial geral (AGI), como HAL 9000 em *2001: Uma Odisseia no Espaço* ou Ava em *Ex Machina* — ou, mais recentemente, com a IA *generativa*. Mas "inteligência artificial" é um termo abrangente para qualquer programa que possa usar informações para tomar decisões ou previsões sem envolvimento humano ativo.

Os sistemas de IA mais básicos são uma série de declarações "if-then-else", com regras e lógica programadas explicitamente por um cientista de dados. No nível mais simples, até mesmo um termostato rudimentar é um sistema de IA baseado em regras: quando programado com regras simples como

```
IF room_temperature < 67, THEN turn_on_heater
```

e

```
IF room_temperature > 72, THEN turn_on_air_conditioner
```

o termostato é capaz de tomar decisões autônomas sem intervenção humana adicional. Em um nível mais complexo, uma grande e intrincada [árvore de decisão](#) baseada em regras programada por especialistas médicos pode analisar sintomas, circunstâncias e comorbidades para ajudar no diagnóstico ou prognóstico.²

Ao contrário dos sistemas especializados, a lógica pela qual um modelo de aprendizado de máquina opera não é explicitamente programada — é *aprendida* por meio da experiência. Considere um programa que filtra spam de e-mail: a IA baseada em regras exige que um cientista de dados defina manualmente critérios precisos e universais para spam; o aprendizado de máquina requer apenas a seleção de um algoritmo apropriado e um conjunto de dados adequado de amostras de e-mails. No treinamento, o modelo vê exemplos de e-mails e prevê quais são spam; o erro das previsões é calculado, e o algoritmo é ajustado para reduzir o erro; esse processo é repetido até que o modelo seja preciso. O modelo de ML recém-treinado aprendeu a identificar spam *implicitamente*.

À medida que as tarefas que um sistema de IA deve realizar ficam mais complexas, os modelos baseados em regras tornam-se cada vez mais frágeis: muitas vezes é impossível definir explicitamente todos os padrões e variáveis que um modelo deve considerar. Os sistemas de aprendizado de máquina emergiram como o modo dominante de inteligência artificial porque os padrões de aprendizado implícitos dos próprios dados são inerentemente mais flexíveis, escaláveis e acessíveis.

Como funciona o aprendizado de máquina

O aprendizado de máquina funciona por meio da lógica matemática. As funcionalidades relevantes (ou "recursos") de cada ponto de dados devem, portanto, ser expressas numericamente, de modo que os próprios dados possam ser alimentados em um algoritmo matemático que "aprenderá" a mapear uma determinada entrada para a saída desejada.

Os pontos de dados no aprendizado de máquina geralmente são representados em forma vetorial, na qual cada elemento (ou dimensão) da [embedding de vetores](#) de um ponto de dados corresponde ao seu valor numérico para uma funcionalidade específica. Para modalidades de dados que são inerentemente numéricas, como dados financeiros ou coordenadas geoespaciais, isso é relativamente simples. Mas muitas modalidades de dados, como texto, imagens, dados de gráficos de redes sociais ou comportamentos de usuários de aplicativos, não são inerentemente numéricas e, portanto, exigem uma engenharia de funcionalidades menos imediatamente intuitiva a ser expressa de uma maneira pronta para ML.

O processo (muitas vezes manual) de escolher quais aspectos dos dados usar em algoritmos de aprendizado de máquina é chamado de [seleção de funcionalidades](#). As técnicas de [extração de funcionalidades](#) refinam os dados até suas dimensões mais relevantes e significativas. Ambos são subconjuntos da [engenharia de funcionalidades](#), a disciplina mais ampla de pré-processamento de dados brutos para uso no aprendizado de máquina. Uma distinção notável do deep learning é que ele normalmente opera com dados brutos e automatiza grande parte do processo de engenharia de funcionalidades (ou pelo menos o processo de extração de funcionalidades). Isso torna o deep learning mais escalável, embora menos interpretável, do que o aprendizado de máquina tradicional.

Otimização e parâmetros do modelo de aprendizado de máquina

Para um exemplo prático, considere um algoritmo de [regressão linear](#) simples para prever os preços de venda de casas com base em uma combinação ponderada de três variáveis: metragem quadrada, idade da casa e número de quartos. Cada casa é representada como um embedding de vetores com três dimensões: `[square`

`footage, bedrooms, age]`

. Uma casa de 30 anos com 4 quartos e 177 metros quadrados poderia ser representada como `[1900, 4, 30]`

(embora, para fins matemáticos, esses números possam primeiro ser dimensionados, ou normalizados, para uma faixa mais uniforme).

O algoritmo é uma função matemática direta:

$$\text{Preço} = (A * \text{metragem quadrada}) + (B * \text{número de quartos}) - (C * \text{Idade}) + \text{Preço base}$$

Aqui, A, B and C são os parâmetros do modelo: ajustá-los ajustará o quanto o modelo pondera cada variável. O objetivo do aprendizado de máquina é encontrar os valores ideais para esses parâmetros do modelo: em outras palavras, os valores dos parâmetros que resultam na função geral produzindo os resultados mais precisos. Embora a maioria das instâncias do mundo real de aprendizado de máquina envolva algoritmos mais complexos, com um número maior de variáveis de entrada, o princípio permanece o mesmo: otimizar os parâmetros ajustáveis do algoritmo para produzir maior precisão.

Tipos de aprendizado de máquina

Todos os métodos de aprendizado de máquina podem ser categorizados como um dos três paradigmas distintos do aprendizado: aprendizado supervisionado, aprendizado não supervisionado ou aprendizado por reforço, com base na natureza de seus objetivos de treinamento e (muitas vezes, mas nem sempre) pelo tipo de dados de treinamento que implicam.

O **aprendizado supervisionado** treina um modelo para prever a saída “correta” para uma determinada entrada. Ele se aplica a tarefas que requerem algum grau de precisão em relação a alguma “**verdade absoluta**” externa, como classificação ou regressão.

O **aprendizado não supervisionado** treina um modelo para discernir padrões intrínsecos, dependências e correlações nos dados. Ao contrário do aprendizado supervisionado, as tarefas de aprendizado não supervisionado não envolvem nenhuma verdade absoluta externa em relação à qual suas saídas devem ser comparadas.

O **aprendizado por reforço (RL)** treina um modelo para avaliar seu ambiente e adotar uma ação que receberá a maior recompensa. Os cenários de RL não implicam a existência de uma verdade absoluta única, mas implicam a existência de ações “boas” e “más” (ou neutras).

O processo de treinamento de ponta a ponta para um determinado modelo pode envolver (e, muitas vezes, envolve) abordagens híbridas que aproveitam mais de um desses paradigmas de aprendizado. Por exemplo, o aprendizado não supervisionado é frequentemente usado para pré-processar dados para uso em aprendizado supervisionado ou por reforço. Os grandes modelos de linguagem (LLMs) normalmente passam por treinamento inicial (pré-treinamento) e [ajuste fino](#) por meio de variantes de aprendizado supervisionado, seguidos de mais ajuste fino por meio de técnicas de RL, como [aprendizado por reforço com feedback humano \(RLHF\)](#).

Em uma prática semelhante, mas distinta, vários métodos de [aprendizado em conjunto](#) agregam as saídas de vários algoritmos.

Aprendizado supervisionado

Os algoritmos de aprendizado supervisionado treinam modelos para tarefas que exigem precisão, como [classificação](#) ou regressão. O aprendizado de máquina supervisionado alimenta modelos de deep learning de última geração e uma ampla gama de modelos de ML tradicionais ainda amplamente empregados em vários setores.

Os modelos de **regressão** preveem valores contínuos, como preço, duração, temperatura ou tamanho. Exemplos de algoritmos de regressão tradicionais incluem [regressão linear](#), regressão polinomial e [modelos de espaço de estado](#).

Os modelos de **classificação** preveem valores discretos, como a categoria (ou *classe*) à qual um ponto de dados pertence, uma decisão binária ou uma ação específica a ser tomada. Exemplos de algoritmos de classificação tradicionais incluem [máquinas de vetores de suporte \(SVMs\)](#), [Naïve Bayes](#) e [regressão logística](#).

Muitos algoritmos de ML supervisionado podem ser usados para qualquer uma das tarefas. Por exemplo, a saída do que é nominalmente um algoritmo de regressão pode posteriormente ser usada para informar uma previsão de classificação.

Para serem medidas e otimizadas quanto à precisão, as saídas de um modelo devem ser comparadas com uma *verdade absoluta*: a saída ideal ou "correta" para qualquer entrada. No aprendizado supervisionado convencional, essa verdade absoluta é fornecida por dados rotulados. Um modelo de detecção de spam de e-mail é treinado em um conjunto de dados de e-mails que foram rotulados como

SPAM

OU NOT SPAM

. Um modelo de [segmentação de imagens](#) é treinado em imagens nas quais cada pixel individual foi anotado por sua classificação. O objetivo do aprendizado supervisionado é ajustar os parâmetros do modelo até que seus resultados correspondam consistentemente à verdade fundamental fornecida por esses rótulos.

Essencial para o aprendizado supervisionado é o uso de uma [função de perda](#) que mede a divergência ("perda") entre a saída do modelo e a verdade absoluta em um lote de entradas de treinamento. O objetivo do aprendizado supervisionado é definido matematicamente como *minimizar a saída de uma função de perda*. Depois que a perda é calculada, vários algoritmos de otimização (a maioria dos quais envolve o cálculo da(s) [derivada\(s\)](#) da função de perda) são usados para identificar ajustes de parâmetros que reduzirão a perda.

Como esse processo tradicionalmente exige um human-in-the-loop para apresentar informações absolutas na forma de anotações de dados, ele é chamado de aprendizado "supervisionado". Dessa forma, o uso de dados rotulados foi historicamente considerado a característica definitiva do aprendizado supervisionado. Mas, no nível mais fundamental, a principal característica do aprendizado supervisionado é a existência de alguma verdade absoluta e o objetivo de treinamento de minimizar a saída da função de perda que mede a divergência dela.

Para acomodar uma noção mais versátil do aprendizado supervisionado, a terminologia moderna de ML usa "supervisão" ou "sinais de supervisão" para se referir genericamente a qualquer fonte de verdade absoluta.

Aprendizado autossupervisionado

A rotulação de dados pode se tornar proibitivamente cara e demorada para tarefas complexas e grandes conjuntos de dados. O [aprendizado autossupervisionado](#) envolve treinamento em tarefas nas quais um sinal de supervisão é obtido diretamente de dados *não rotulados* — portanto, "auto" supervisionado.

Por exemplo, os [autocodificadores](#) são treinados para compactar (ou *codificar*) os dados de entrada e, em seguida, reconstruir (ou *decodificar*) a entrada original usando essa representação compactada. Seu objetivo de treinamento é minimizar o *erro de reconstrução*, usando a própria entrada original como verdade absoluta. O aprendizado autossupervisionado também é o principal método de treinamento para LLMs: os modelos recebem amostras de texto com determinadas palavras ocultas ou mascaradas e têm a tarefa de prever as palavras que faltam.

O aprendizado autossupervisionado é frequentemente associado ao [aprendizado por transferência](#), pois pode fornecer [modelos de base](#) com amplos recursos que receberão, então, [ajuste fino](#) para tarefas mais específicas.

Aprendizado semissupervisionado

Enquanto o aprendizado autossupervisionado é essencialmente um aprendizado supervisionado em dados não rotulados, os métodos de [aprendizado semissupervisionado](#) usam tanto dados rotulados quanto dados não rotulados. Em termos gerais, o aprendizado semissupervisionado compreende técnicas que usam informações dos dados rotulados disponíveis para fazer suposições sobre os pontos de dados não rotulados, de modo que estes possam ser incorporados aos fluxos de trabalho de aprendizado supervisionado.

Aprendizado não supervisionado

Algoritmos de aprendizado de máquina não supervisionado discernem padrões intrínsecos em dados não rotulados, como similaridades, correlações ou agrupamentos potenciais. Eles são mais úteis em cenários em que esses padrões não são necessariamente aparentes para observadores humanos. Como o aprendizado não supervisionado não pressupõe a preexistência de uma saída "correta" conhecida, ele não exige sinais de supervisão ou funções de perda convencionais — portanto, "não supervisionado".

A maioria dos métodos de aprendizado não supervisionado executa uma das seguintes funções:

Os algoritmos de **agrupamento** particionam pontos de dados não rotulados em "clusters" ou agrupamentos, com base na proximidade ou semelhança entre si. Eles são normalmente usados para tarefas como segmentação de mercado ou detecção de fraude. Algoritmos de agrupamento proeminentes incluem agrupamento K-means, modelos de mistura gaussiana (GMMs) e métodos baseados em densidade, como DBSCAN.

Os algoritmos de **associação** discernem correlações, como entre uma ação específica e certas condições. Por exemplo, empresas de comércio eletrônico como a Amazon usam modelos de **associação** não supervisionados para alimentar mecanismos de recomendação.

Os algoritmos de **redução de dimensionalidade** reduzem a complexidade dos pontos de dados, representando-os com um número menor de funcionalidades (ou seja, em menos dimensões) ao mesmo tempo em que **preservam suas características significativas**. Eles são frequentemente usados para pré-processar dados, bem como para tarefas como compactação ou visualização de dados. Algoritmos proeminentes de redução de dimensionalidade incluem **autocodificadores**, **análise de componentes principais (PCA)**, **análise discriminante linear (LDA)** e **embedding estocástico de vizinhos com distribuição t (t-SNE)**.

Como o nome sugere, os algoritmos de aprendizado não supervisionado podem ser, de forma geral, vistos como "otimizando a si mesmos". Por exemplo, **esta animação** demonstra como um algoritmo de agrupamento k-means otimiza iterativamente o centroide de cada cluster isoladamente. O desafio de treinar modelos não supervisionados, portanto, concentra-se no pré-processamento eficaz de dados e no **ajuste adequado de hiperparâmetros** que influenciam o processo de aprendizado, mas que não podem ser aprendidos, como a **taxa de aprendizado** ou o número de clusters.

Aprendizado por reforço (RL)

Enquanto o aprendizado supervisionado treina modelos otimizando-os para corresponder a exemplares ideais e os algoritmos de aprendizado não

supervisionado se ajustam a um conjunto de dados, os modelos de **aprendizado por reforço** são treinados holisticamente por meio de tentativa e erro. Eles são usados de forma proeminente em robótica, videogames, **modelos de raciocínio** e outros casos de uso em que o espaço de soluções e abordagens possíveis é particularmente grande, aberto ou difícil de definir. Na literatura de RL, um sistema de IA é frequentemente chamado de "agente".

Em vez dos pares independentes de dados de entrada-saída usados no aprendizado supervisionado, o aprendizado por reforço (RL) opera em tuplas de dados estado-ação-recompensa interdependentes. Em vez de minimizar o erro, o objetivo do aprendizado por reforço é otimizar os parâmetros para maximizar a recompensa.

Um framework matemático para aprendizado por reforço é construído principalmente com base nos seguintes componentes:

O **espaço de estado** contém todas as informações disponíveis relevantes para as decisões que o modelo pode tomar. O estado normalmente muda com cada ação que o modelo executa.

O **espaço de ação** contém todas as decisões que o modelo pode tomar em um momento. Em um jogo de tabuleiro, por exemplo, o espaço de ação compreende todos os movimentos legais disponíveis em um determinado momento. Na geração de texto, o espaço de ação abrange todo o "vocabulário" de tokens disponíveis para um LLM.

O **signal de recompensa** é o feedback (positivo ou negativo, normalmente expresso como um valor em escala) fornecido ao agente como resultado de cada ação. O valor do sinal de recompensa pode ser determinado por regras explícitas, por uma *função de recompensa* ou por um *modelo de recompensa* treinado separadamente.

Uma **política** é o "processo de pensamento", que impulsiona o comportamento de um agente de aprendizado por reforço. Em termos matemáticos, uma política (π) é uma função que recebe um estado (s) como entrada e retorna uma ação (a): $\pi(s) \rightarrow a$.

Em métodos de RL *baseados em políticas* , como a otimização de políticas proximais (PPO), o modelo aprende uma política diretamente. Em métodos *baseados em valor* , como o Q-learning, o agente aprende uma função de valor que calcula uma pontuação para o quão “bom” é cada estado e, em seguida, escolhe ações que levam a estados de valor mais alto. Considere um labirinto: um agente baseado em políticas pode aprender "nesse canto, vire à esquerda", enquanto um agente baseado em valores aprende uma pontuação para cada posição e simplesmente se move para uma posição adjacente com uma pontuação melhor. Abordagens híbridas, como métodos ator-crítico, aprendem uma função de valor que é, então, usada para otimizar uma política.

No aprendizado por reforço profundo, a política é representada como uma [rede neural](#).

FONTE: <https://www.ibm.com/br-pt/think/topics/machine-learning>